

# developerWorks<sub>®</sub>

## double-checked lockingとSingletonパターン この破たんしたプログラミング・イディオムを多角的に検討する

Peter Haggar

Senior Software Engineer IBM

2002年 5月 01日

すべてのプログラム言語には、それぞれのイディオムがあります。それらの多くは、知っておいて損がなく、使う価値があるもので、プログラマーたちは、それらの作成、学習、および実装に貴重な時間を費やしています。問題は、いくつかのイディオムが、触れ込みとは異なっていたり、説明どおりに機能しなかったりすることが、後になって判明することです。Javaプログラム言語には、いくつかの便利なプログラミング・イディオムが含まれています。一方で、その後の研究により、使用すべきでないことが明らかになったイディオムも、いくつかあります。double-checked lockingは、そうした、決して使用すべきでないイディオムの1つです。Peter Haggar氏はこの記事で、double-checked lockingイディオムのルーツを探り、それがなぜ開発されたのか、また、なぜ機能しないのかを検討します。

Singleton作成パターンは、一般的なプログラミング・イディオムの1つです。複数のスレッドで使用する場合には、なんらかのタイプの同期化を使用する必要があります。Javaプログラマーたちは、より効率の高いコードを作成することを目指して、コードの同期化を減らすためにSingleton作成パターンで使用する、double-checked lockingイディオムを作成しました。しかし、ほとんど知られていないJavaメモリー・モデルの詳細が原因で、このdouble-checked lockingイディオムは、動作が保証されていません。常に障害が起こるわけではなく、散発的に障害が起こるのです。さらに、その障害の理由が分かりにくく、Javaメモリー・モデルのささいな事項に関連しています。こうしたことがあるため、double-checked lockingに起因するコード障害を調べることは、きわめて困難です。この記事の、これ以降の部分では、double-checked lockingイディオムがどこで破たんするのかを理解するために、このイディオムについて詳しく検討します。

## Singleton作成イディオム

double-checked lockingイディオムの起源を知るためには、一般的なSingleton作成イディオムを理解する必要があります。リスト1に、このイディオムを示します。

## リスト1. Singleton作成イディオム

```
import java.util.*;
class Singleton
 private static Singleton instance;
 private Vector v;
 private boolean inUse;
 private Singleton()
   v = new Vector();
   v.addElement(new Object());
    inUse = true;
 public static Singleton getInstance()
    if (instance == null)
                                    //1
     instance = new Singleton(); //2
    return instance;
                                    //3
}
```

このクラスの設計では、Singleton オブジェクトが一つだけ作成されるようになっています。このコンストラクターはprivate と宣言されていて、getInstance()メソッドは1つのオブジェクトだけを作成します。このような実装は、シングルスレッド・プログラムの場合には問題ありません。しかし、複数のスレッドが導入される場合には、getInstance()メソッドを同期化によって保護しなければなりません。getInstance()メソッドが保護されていないと、Singleton オブジェクトの2つの異なるインスタンスが戻される可能性があります。ここで、2つのスレッドが同時にgetInstance()メソッドを呼び出し、さらに以下の一連のイベントが発生するものとします。

- 1. スレッド1が、getInstance() メソッドを呼び出し、//1でinstance がnull であることを判別します。
- 2. スレッド1はif ブロックに入りますが、//2の行を実行する前に スレッド2に取って代わられます。
- 3. スレッド2は、getInstance() メソッドを呼び出し、//1でinstance がnull であることを判別します。
- 4. スレッド2はif ブロックに入り、新しいSingleton オブジェクトを作成して、//2でこの新規 オブジェクトを変数instance に代入します。
- 5. スレッド2は //3でSingleton オブジェクト参照を戻します。
- 6. スレッド2がスレッド1に取って代わられます。
- 7. スレッド1は中断個所から再開し、行 //2を実行して、別のSingleton オブジェクトが作成されます。
- 8. スレッド1は //3でこのオブジェクトを戻します。

この結果、getInstance()メソッドによって作成されるSingletonオブジェクトは1つだけであると想定されているにもかかわらず、このオブジェクトが2つ作成されることになります。この問題は、リスト2に示すように、getInstance()メソッドを同期化して、一度に1つのスレッドだけがこのコードを実行できるようにすることにより、解決できます。

#### リスト2. スレッド・セーフなgetInstance() メソッド

リスト2のコードは、getInstance()メソッドに対するマルチスレッド・アクセスでは、問題なく機能します。しかし、これを分析すると、同期化が必要なのは、メソッドの最初の呼び出しのときだけであることが分かります。それ以降の呼び出しでは同期化は必要ありません。これは、//2のコードを実行する呼び出しは最初の呼び出しだけであり、同期化を必要とするのはこの行だけであるためです。それ以外のすべての呼び出しは、instanceが非nullであることを判別し、それを戻します。最初の呼び出し以外は、どの呼び出しでも、複数のスレッドが同時に実行されても問題ありません。ただし、このメソッドはsynchronizedであるため、最初の呼び出しのとき以外は必要がないにもかかわらず、メソッドを呼び出すたびに同期化するコストを払うことになります。

このメソッドの効率を高めることを目指して、double-checked lockingというイディオムが作成されました。この考えは、メソッドの最初の呼び出しを除くすべての呼び出しで高コストな同期を避けるというものです。同期化のコストはJVMごとに異なります。最初のころは、このコストは非常に高くなることがありました。より進んだJVMが登場するようになると、同期化のコストは低下しましたが、それでも、synchronized されたメソッドまたはブロックに入ったりそこから出たりすることで、パフォーマンスが悪影響を受けます。JVMテクノロジーが進歩したとはいえ、プログラマーは、処理時間を不必要に費やすことを望んではいないのです。

同期化が必要なのはリスト2の行 //2だけですので、リスト3に示すように、同期化されたブロック内でラップすることができます。

#### リスト3. getInstance() メソッド

```
public static Singleton getInstance()
{
   if (instance == null)
   {
      synchronized(Singleton.class) {
        instance = new Singleton();
      }
   }
   return instance;
}
```

リスト3のコードには、複数のスレッドおよびリスト1で示されたものと同じ問題があります。 instance がnull である場合に、2つのスレッドが同時にif ステートメントに入る可能性があります。そして、1つのスレッドがsynchronized ブロックに入ってinstance を初期化し、もう一方のスレッドはブロックされます。最初のスレッドがsynchronized ブロックから出ると、待機していたスレッドがこのブロックに入り、もう1つのSingleton oオブジェクトを作成します。2番目のスレッドがsynchronized ブロックに入るときには、instance が非null であるかどうかの検査が行われないことに注意してください。

#### double-checked locking

リスト3の問題を修正するためには、instance をもう一度検査する必要があります。ここから、「double-checked locking」という名前が付けられました。リスト3にdouble-checked lockingイディオムを適用したものがリスト4です。

#### リスト4. double-checked lockingの例

double-checked lockingの背景となる理屈は、//2で行われる2番目の検査により、リスト3の場合のように2つの異なるsingleton オブジェクトが作成される可能性がなくなるということです。ここで、次の一連のイベントが起こるものとします。

- 1. スレッド1がgetInstance() メソッドに入ります。
- 2. instance がnull であるため、スレッド1は //1でsynchronized ブロックに入ります。
- 3. スレッド1がスレッド2に取って代わられます。
- 4. スレッド2がgetInstance() メソッドに入ります。
- 5. instance はまだnull であるため、スレッド2は //1でロックを獲得しようとします。しかし、 スレッド1がロックを保持しているため、スレッド2は //1でブロックされます。
- 6. スレッド2がスレッド1に取って代わられます。
- 7. スレッド1が実行されます。//2でインスタンスがまだnull になっているため、スレッド1 はSingleton オブジェクトを作成し、その参照をinstance に代入します。
- 8. スレッド1がsynchronized ブロックを抜け出し、getInstance() メソッドからインスタンスを戻します。
- 9. スレッド1がスレッド2に取って代わられます。
- 10. スレッド2が //1でロックを獲得し、instance がnull になっているかどうかを調べます。
- 11. instance は非null になっているため、2番目のSingleton オブジェクトは作成されず、スレッド1で作成されたオブジェクトが戻されます。

double-checked lockingの背景となっている理屈は申し分ありません。残念ながら、現実はまったく異なります。double-checked lockingの問題は、シングル・プロセッサー・マシンまたはマルチプロセッサー・マシンで機能することが保証されないことです。

double-checked lockingの障害の問題点は、JVMの実装のバグのせいではなく、現在のJavaプラットフォームのメモリー・モデルが原因となっています。このメモリー・モデルは、いわゆる「アウトオブオーダー書き込み」を許し、それがこのイディオムの障害の主要な原因となっています。

## アウトオブオーダー書き込み

この問題を理解するためには、上記のリスト4の行 //3を再検討する必要があります。この行のコードはSingleton オブジェクトを作成し、このオブジェクトを参照するために変数instance を

初期化します。この行のコードの問題は、Singleton コンストラクターの本体が実行される前に、変数instance が非null になる可能性があることです。

え? そんなはずはないだろうって?しかし、事実そのとおりなのです。なぜこのようなことが起こるのかを説明するに先立ち、double-checked lockingイディオムが破たんする理由を調べるしばらくの間、この事実を受け入れてください。ここで、リスト4のコードについて、次の一連のイベントが起こるものと考えてみてください。

- 1. スレッド1がgetInstance() メソッドに入ります。
- 2. instance がnull であるため、スレッド1は //1でsynchronized ブロックに入ります。
- 3. スレッド1は //3に進んでインスタンスを非null にしますが、このときにはまだ コンストラクターが実行されていません。
- 4. スレッド1がスレッド2に取って代わられます。
- 5. スレッド2は、インスタンスがnull になっているかどうかを調べます。インスタンスがnull になっていないため、スレッド2は、完全に構成され、しかし部分的にしか初期化されていないSingleton オブジェクトを、instance 参照に対して戻します。
- 6. スレッド2がスレッド1に取って代わられます。
- 7. スレッド1は、コンストラクターを実行してそれに対する参照を戻すことにより、Singleton オブジェクトの初期化を完了します。

この一連のイベントの結果、ある期間のあいだ、スレッド2が、コンストラクターが実行されていないオブジェクトを戻すことになります。

これがどのようにして生じるのかを調べるために、instance =new Singleton(); の行を次の疑似 コードで置き換えてください。

この疑似コードは、単に可能性があるというだけでなく、いくつかのJITコンパイラーで実際に行われていることなのです。実行の順番が、順不同になってしまっていることが分かりますが、現在のメモリー・モデルではこれが許されてしまうのです。JITコンパイラーがこのようなことを行う以上、double-checked lockingの問題は、単なる教室での演習として片付けるわけにはいきません。

このようすを理解するために、リスト5のコードについて考えてみてください。これには、getInstance()メソッドから余分な部分を取り除いたものが含まれています。作成されるアセンブリー・コード(リスト6)を検討しやすくするために、「double-check」の要素を除去してあります。ここでの関心事は、instance=new Singleton();の行がJITコンパイラーでどのようにコンパイルされるのかということだけです。また、コンストラクターがアセンブリー・コードでどのように実行されるのかを理解しやすくするために、簡単なコンストラクターを用意しました。

#### リスト5. アウトオブオーダー書き込みを示すためのSingletonクラス

```
class Singleton
{
  private static Singleton instance;
  private boolean inUse;
  private int val;

private Singleton()
{
   inUse = true;
   val = 5;
}
  public static Singleton getInstance()
{
   if (instance == null)
      instance = new Singleton();
   return instance;
}
```

リスト6は、リスト5のgetInstance() メソッドの本体からSun JDK 1.2.1 JITコンパイラーによって生成された、アセンブリー・コードを含んでいます。

#### リスト6. リスト5のコードから生成されたアセンブリー・コード

```
;asm code generated for getInstance
                                             ;load instance ref
054D20B0
           mov
                        eax, [049388C8]
054D20B5
                                             ;test for null
           test
                        eax, eax
054D20B7
                        054D20D7
           jne
054D20B9
           mov
                        eax, 14C0988h
054D20BE
           call
                        503EF8F0
                                             ;allocate memory
054D20C3
           mov
                        [049388C8], eax
                                             ;store pointer in
                                             ;instance ref. instance
                                             ;non-null and ctor
                                             ;has not run
                        ecx, dword ptr [eax]
054D20C8
           mov
                                             ;inline ctor - inUse=true;
054D20CA
           mov
                        dword ptr [ecx],1
                        dword ptr [ecx+4],5; inline ctor - val=5;
054D20D0
           mov
054D20D7
                        ebx, dword ptr ds:[49388C8h]
           mov
054D20DD
                        054D20B0
           jmp
```

注: 以下の説明では、命令アドレスの値がすべて054D20 で始まっていますので、命令アドレスの最後の2つの値を使用してアセンブリー・コードの行を参照しています。例えば、B5 はtest eax, eax を表しています。

このアセンブリー・コードは、無限ループ内でgetInstance()メソッドを呼び出すテスト・プログラムを実行して生成されたものです。このプログラムの実行中に、Microsoft Visual C++デバッガーを実行し、テスト・プログラムに対応するJavaプロセスに接続してください。そして、実行を中断して、無限ループを表すアセンブリー・コードを見付けてください。

アセンブリー・コードの最初の2行のBO およびB5 では、メモリー位置049388C8 からeax にinstance 参照をロードし、null になっているかどうかを調べます。これは、リスト5 のgetInstance() メソッドの最初の行に対応しています。このメソッドが初めて呼び出されたときには、instance はnull になっていて、コードはB9 に進みます。BE のコードは、ヒープ内のメモリーをSingleton オブジェクト用に割り振り、そのメモリーへのポインターをeax に保管します次の行c3 では、eax 内のポインターを受け取り、それを、メモリー位置049388C8 にあるイン

スタンス参照に戻して保管します。これにより、instance が非null になり、有効なSingleton オブジェクトを表すようになります。ただし、このオブジェクトのコンストラクターはまだ実行されていません。このような状態では、double-checked lockingは破たんします。そして、行c8でinstance ポインターが参照読み出し(dereference)され、ecx に保管されます。行ca およびDOは、値true および5をSingleton オブジェクトに保管する、インライン・コンストラクターを表しています。行c3を実行してからコンストラクターを完了するまでの間にこのコードが割り込みを受けると、double-checked lockingは失敗します。

必ずしもすべてのJITコンパイラーが上記のようなコードを生成するわけではありません。コンストラクターが実行されてからでなければinstance を非null にしないようなコードを生成するものもあります。IBM SDK for JavaテクノロジーV1.3とSun JDK 1.3は、ともにこのようなコードを生成します。しかし、だからといって、このようなインスタンスでdouble-checked lockingを使用すべきであるというわけではありません。障害の原因となりうるものが、ほかにもあるのです。また、自分のコードがどのJVMで実行されるのかは、必ずしも常に分かるとは限りませんし、JITコンパイラーが、このイディオムを破たんさせるコードを生成するように変更される可能性は、常にあるのです。

#### double-checked locking: その2

現行のdouble-checked lockingコードが機能しないので、リスト7に示すような、このコードの別バージョンを利用して、上に示したアウトオブオーダー書き込みの問題を避けようとしてみました。

#### リスト7. アウトオブオーダー書き込みの問題を解決する試み

リスト7のコードを見ると、ややおかしな方向に進んでいることに気が付くはずです。そもそも、double-checked lockingは、単純な3行のgetInstance()メソッドの同期化を回避する手段として作り出されたものでした。リスト7のコードは、手に余るほど肥大化しています。さらに、このコードでは問題が修正されないのです。注意深く検討してみると、その理由が明らかになります。

このコードはアウトオブオーダー書き込みの問題を避けようとしています。そのために、ローカル変数inst と2番目のsynchronized ブロックを導入しています。この理屈は、次のようになっています。

- 1. スレッド1がgetInstance() メソッドに入ります。
- 2. instance がnull であるため、スレッド1は //1で最初のsynchronized ブロックに入ります。
- 3. ローカル変数inst がinstance の値を入手します。この値は、//2ではnull になっています。
- 4. inst がnull であるため、スレッド1は //3で2番目のsynchronized ブロックに入ります。
- 5. そしてスレッド1が //4でコードの実行を開始し、inst を非null にしますが、この時点ではまだSingleton のコンストラクターが実行されていません。(これはまさに、上で見たアウトオブオーダー書き込みの問題です。)
- 6. スレッド1がスレッド2に取って代わられます。
- 7. スレッド2がgetInstance() メソッドに入ります。
- 8. instance がnull であるため、スレッド2は //1で最初のsynchronized ブロックに入ろうとします。現在スレッド1によってこのロックが保持されているため、スレッド2はブロックされます。
- 9. そして、スレッド1が //4の実行を完了します。
- 10. スレッド1はその後、完全に構成されたSingleton オブジェクトを //5で変数instance に代入し、両方のsynchronized ブロックを終了します。
- 11. スレッド1がinstance を戻します。
- 12. その後で、スレッド2が実行され、//2でinstance をinst に代入します。
- 13. スレッド2は、instance が非null であることを確認し、それを戻します。

ここで鍵となる行は //5です。この行は、instance が必ずnull になることを保証するか、あるいは完全に構成されたSingleton オブジェクトを参照するものと想定されています。理論と現実のくい違いが起こると、問題が発生します。

現行のメモリー・モデルの定義により、リスト7のコードは機能しません。Java言語仕様 (JLS) では、synchronized ブロック内のコードがsynchronized ブロックの外側に移動しないことが求められています。しかし、synchronized ブロックに含まれていないコードをsynchronized ブロックの中に移動することはできない、とは言っていません。

JITコンパイラーは、この部分を最適化の好機として捕えるはずです。この最適化により、//4のコードと //5のコードが除去され、それらが結合され、リスト8に示すコードが生成されることが考えられます。

#### リスト8. リスト7のコードを最適化したもの

この最適化が行われると、前に述べたものと同じアウトオブオーダー書き込みの問題が生じます。

#### volatileを使ってみますか?

もう1つのアイデアとして、変数inst およびinstance にvolatile というキーワードを使用する方法があります。JLS (参考文献を参照) によると、volatile として宣言された変数は、順序が一貫していて、従って順序変更されないものと想定されています。しかし、volatile を使用してdouble-checked lockingの問題を修正しようとすると、2つの問題が生じます。

- この場合の問題は、順序の一貫性に関するものではありません。コードが、順序変更されるのではなく、移動されるのです。
- 多くのIVMでは、順序の一貫性について、volatile が正しく実装されません。

2番目の問題は、詳しく採り上げる価値があります。ここで、リスト9に示すコードについて考えてみてください。

#### リスト9. volatileに関する順序の一貫性

JLSによると、stop およびnum はvolatile として宣言されるため、順序が一貫している必要があります。これは、stop がtrue の場合、num を100 に設定していなければならないということを意味します。ただし、多くのJVMはvolatile の順序一貫性機能を実装していないため、この振る舞いは当てになりません。したがって、スレッド1がfoo を呼び出し、スレッド2が同時にbar を呼び出す場合には、スレッド1では、num が100 に設定される前にstop がtrue に設定される可能性があります。これが原因で、スレッド2が、stop がtrue であるにもかかわらず、num がまだ0 に設定されていると認識することがあります。ほかにもvolatile と64ビット変数のアトミシティに関する問題がありますが、これは、この記事の範囲を超えています。このトピックの詳細については、参考文献を参照してください。

## 解決策

要するに、double-checked lockingは(いかなる形式のものであっても)、どのJVM実装でも動作するとは保証できないため、使用すべきではありません。JSR-133では、メモリー・モデルに関する

問題に対処していますが、double-checked lockingはこの新規メモリー・モデルではサポートされません。したがって、ユーザーがとりうる選択肢としては、次の2つがあります。

- リスト2に示したような、getInstance()メソッドの同期化を受け入れる。
- 同期化を行わず、static フィールドを使用する。

2番目の選択肢をリスト10に示します。

#### リスト10. 静的フィールドを使用したSingleton実装

```
class Singleton
{
  private Vector v;
  private boolean inUse;
  private static Singleton instance = new Singleton();

  private Singleton()
  {
      v = new Vector();
      inUse = true;
      //...
  }

  public static Singleton getInstance()
  {
      return instance;
   }
}
```

リスト10のコードは、同期化を使用せず、また、static getInstance()メソッドへの呼び出しが行われるまではSingletonオブジェクトを作成しないようになっています。これは、同期化を行わないことを目標とする場合には、優れた選択肢です。

#### ストリングは不変ではない

アウトオブオーダー書き込みの問題と、コンストラクターが実行される前に参照が非nullになることを考えると、読者はString クラスに興味を抱くことと思います。次のコードについて考えてください。

```
private String str;
//...
str = new String("hello");
```

String クラスは、不変なものと想定されています。しかし、上に述べたアウトオブオーダー書き込みの問題を考えると、それが原因で、ここでも問題が生じる可能性があるのではないのでしょうか?その恐れは確かにあります。2つのスレッドがString str にアクセスする場合について考えてください。一方のスレッドで、str 参照が、まだコンストラクターが実行されていないString オブジェクトを参照している可能性があります。実際、リスト11のコードは、このような事態が生じていることを示しています。断っておきますが、このコードが破たんするのは、私がテストした古いJVMの場合だけです。IBM 1.3 JVMでもSun 1.3 JVMでも、期待どおりに不変のString が生成されます。

#### リスト11.変化しやすいStringの例

```
class StringCreator extends Thread
```

```
MutableString ms;
 public StringCreator(MutableString muts)
   ms = muts;
 public void run()
    while(true)
                                              //1
      ms.str = new String("hello");
class StringReader extends Thread
 MutableString ms;
 public StringReader(MutableString muts)
   ms = muts;
 public void run()
   while(true)
     if (!(ms.str.equals("hello")))
                                              //2
        System.out.println("String is not immutable!");
        break:
   }
 }
class MutableString
                                              //3
 public String str;
 public static void main(String args[])
   MutableString ms = new MutableString(); //4
   new StringCreator(ms).start();
                                              //5
    new StringReader(ms).start();
                                              //6
 }
}
```

このコードの //4では、//3での2つのスレッドによって共用されているString 参照を含む、MutableString クラスを作成しています。//5と //6では、2つの別個のスレッドでStringCreator とStringReader の2つのオブジェクトを作成し、そこではMutableString オブジェクトへの参照を渡しています。StringCreator クラスは無限ループに入り、//1で「hello」という値のString オブジェクトを作成します。StringReader も無限ループに入り、//2で現行のString オブジェクトの値が「hello」になっているかどうかを調べます。この値が「hello」になっていない場合には、StringReader スレッドはメッセージを出力して停止します。String クラスが不変であれば、このプログラムからは何も出力されないはずです。StringReader がstr 参照を、「hello」という値のString オブジェクトとして判定しないのは、アウトオブオーダーの問題が生じた場合だけです。

このコードをSun JDK 1.2.1などの古いJVMで実行すると、アウトオブオーダーの問題が発生し、したがって、String は不変ではなくなります。

#### 要約

プログラマーたちは、Singletonで高コストな同期化を回避するために、工夫を凝らして、double-checked lockingイディオムを考案しました。残念ながら、このイディオムが、現行のメモリー・

モデルが原因で安全なプログラミング構成概念ではないことが明らかになったのは、これがかなり広く使われるようになった後のことでした。メモリー・モデルの、ぜい弱な部分を改良するための努力が行われています。しかし、新しく提案されたメモリー・モデルでも、double-checked lockingは通用しません。この問題に対する最良の解決策は、同期化を受け入れるか、あるいはstatic field を使用することです。

#### 著者について

#### Peter Haggar

Peter Haggarは、アメリカのノースカロライナ州にあるResearch Triangle Parkに勤務するIBMシニア・ソフトウェア・エンジニアであり、「 Practical Java Programming Language Guide」 (Addison-Wesley 社発行) の著者です。彼はまた、Javaプログラミングに関する多数の記事を発表しています。彼は、開発ツール、クラス・ライブラリー、およびオペレーティング・システムなど、幅広いプログラミング経験を持っています。IBMでは、未来のインターネット・テクノロジーに携わり、現在は高性能なWebサービスを中心に研究を行っています。Peterは、多くの業界の会議で頻繁に技術的なスピーチを行っています。彼はIBMに14年以上にわたって勤務しており、また、Clarkson Universityよりコンピューター・サイエンスのB.S. を取得しています。

#### © Copyright IBM Corporation 2002

(www.ibm.com/legal/copytrade.shtml)

#### 商標

(www.ibm.com/developerworks/jp/ibm/trademarks/)